

Documentação da API OpenAI compatível do Llama.cpp (setup com dois serviços)

Atualizado em 16/08/2025 19:11.

Visão geral

Seu docker-compose agora sobe dois serviços:

Serviço	Função	Base URL
chat (8000)	/chat/completions e /completions	http://localhost:8000/v1
embeddings (8001)	/embeddings	http://localhost:8001/v1

Chat/Completions (porta 8000)

GET /v1/models POST /v1/chat/completions POST /v1/completions GET /v1/health (opcional) cURL exemplos: curl -s http://localhost:8000/v1/models -H "Authorization: Bearer dummy" curl -s http://localhost:8000/v1/chat/completions \ -H "Authorization: Bearer dummy" -H "Content-Type: application/json" \ -d '{"model": "default", "messages": [{"role": "user", "content": "Oi!"}]}' curl -s http://localhost:8000/v1/completions \ -H "Authorization: Bearer dummy" -H "Content-Type: application/json" \ -d '{"model": "default", "prompt": "Explique RAG em 2 linhas."}'

Embeddings (porta 8001)

GET /v1/models POST /v1/embeddings GET /v1/health (opcional) cURL exemplo: curl -s http://localhost:8001/v1/embeddings \ -H "Authorization: Bearer dummy" -H "Content-Type: application/json" \ -d '{"model": "default", "input": ["texto 1", "texto 2"]}'

Erros comuns

404 not_found_error: rota incorreta (/v1). 501 not_supported_error: você tentou usar /chat/completions em um servidor iniciado com --embeddings. No setup atual, 8000 é chat/completions e 8001 é embeddings.